

Reporte Técnico Final

Potencial Solar en Cubiertas de Municipios PDET — Flujo Geoespacial NoSQL Reproducible para la UPME

Curso: Administración de Bases de Datos **Entregable:** Semana 5 — Reporte Técnico Final y Recomendaciones **Fecha:** 2026-06-01 **Repositorio:** github.com/Jxxxlian/Proyecto-DBA

Resumen Ejecutivo

La Unidad de Planeación Minero Energética (UPME) de Colombia está evaluando ubicaciones para proyectos piloto de granjas solares en municipios PDET — los 170 territorios priorizados por el *Decreto 893 de 2017* para el desarrollo con enfoque territorial en el posconflicto.

Este proyecto entrega un **flujo geoespacial NoSQL reproducible** que cuantifica el **área de cubierta disponible** en cada municipio PDET a partir de dos conjuntos de datos abiertos de huellas de edificios (Microsoft Bing y Google Open Buildings v3) y prioriza los municipios por su potencial solar.

Cifras principales

- **169 de 170** municipios PDET cargados con geometría oficial
- **1.763.356** edificios de Microsoft + **2.691.812** edificios de Google etiquetados con su municipio contenedor
- **~222 km²** de área total de cubiertas PDET — ambas fuentes independientes convergen en este número (con menos de 1 % de diferencia)
- Los **5 mejores candidatos** para el piloto de UPME son **Santa Marta, Valledupar, Buenaventura, Florencia y Turbo** (combinan ~46 km² de cubierta)
- El **76 % de los municipios compartidos** muestra divergencia mayor al 20 % entre fuentes en el conteo bruto de edificios — *por esto el proyecto exige comparar dos datasets*
- Umbral de confianza recomendado para Google: **≥ 0,70** (conserva el 93 % del área total y elimina ruido probable)

Recomendaciones finales para la UPME

1. **Priorizar los 5 municipios PDET urbanos del top** para la primera granja solar piloto. Tienen la mayor área absoluta de cubierta y la mejor concordancia entre fuentes.
 2. **Usar Google con confidence ≥ 0,70** como inventario principal; utilizar Microsoft como verificación cruzada.
 3. **Verificar en terreno antes de comprometer capital** en cualquier municipio con divergencia mayor al 20 % entre fuentes (126 de 165 municipios compartidos).
 4. **Re-ejecutar el flujo anualmente** cuando Microsoft y Google publiquen nuevas detecciones. La metodología es reproducible; el tiempo total desde un clon limpio es de menos de 30 minutos más el tiempo de descarga.
-

1. Contexto del Proyecto y Objetivos

1.1 El mandato de la UPME

La UPME es la agencia colombiana responsable de planificar la infraestructura energética nacional. Como parte de la estrategia de transición energética del país, la UPME pretende desplegar granjas solares piloto en regiones geográficamente desatendidas y está priorizando **territorios PDET** — municipios designados por el Decreto 893/2017 como focales para el desarrollo posconflicto.

La pregunta estratégica que la UPME planteó: "¿En qué municipios PDET existe la mayor área de cubiertas adecuada para la instalación de paneles solares?"

La premisa subyacente es directa y explícita: **mayor área de cubierta implica mayor potencial para generación fotovoltaica distribuida**. El proyecto no calcula kWh, eficiencia de paneles ni retornos financieros — esos son dominio de la UPME. El entregable es el sustrato geográfico (conteos y áreas de cubierta por municipio) sobre el cual esos análisis posteriores se construyen.

1.2 Requisitos del proyecto (de `reference.md`)

Requisito	Origen	Cómo se abordó
Usar una solución NoSQL	Mandato de modernización de la UPME	MongoDB 7 con GeoJSON + 2dsphere
Comparar al menos dos conjuntos abiertos de huellas de edificios	Documento de referencia §2	Microsoft Bing + Google Open Buildings v3
Enfocar en los 170 municipios PDET	Documento de referencia §2	Filtrado contra la lista oficial de la ART (Decreto 893/2017)
Producir una metodología reproducible	Documento de referencia §1	Todos los scripts versionados; ruta de reproducción en 5 comandos
Entregar un reporte técnico con recomendaciones	Documento de referencia §3.1.5	<i>Este documento</i>

1.3 Decisiones de alcance

Decisión	Justificación
Dos datasets (Microsoft + Google) en lugar de tres	El documento de referencia exige <i>al menos</i> dos. TUM GlobalBuildingAtlas fue revisado pero añade complejidad operativa sin cambiar la metodología.
Carga limitada a PDET (descartar edificios fuera de PDET al ingreso)	El alcance es solo PDET. Cargar los ~29M de edificios fuera de PDET aumentaría el almacenamiento 6× sin valor analítico.
Geometrías almacenadas en EPSG:4326; área calculada en EPSG:9377	EPSG:4326 es requerido por el índice <code>2dsphere</code> de Mongo. EPSG:9377 (MAGNA-SIRGAS Origen Nacional) es el CRS oficial de Colombia para medir áreas con precisión.
Cruce espacial en el INSERT, no como ETL posterior	Cambia un costo único de ingesta por lecturas ilimitadas y baratas; forma adecuada para una carga de trabajo de lectura intensa.

2. Arquitectura del Sistema

2.1 Stack tecnológico

- **MongoDB 7.0** — almacenamiento principal, accedido mediante el driver oficial de Python `pymongo`
- **Mongo Express** — interfaz web de inspección, útil para demos
- **Docker Compose** — orquesta Mongo + Mongo Express en dos contenedores
- **Python 3.13** con `geopandas` , `shapely` , `pyproj` , `folium` , `matplotlib` , `pandas` , `requests` — ETL, análisis y visualización

2.2 Colecciones de MongoDB

Colección	Granularidad	Documentos finales
municipalities	Un polígono de municipio PDET	169
buildings_ms	Una huella de edificio de Microsoft dentro de PDET	1.763.356
buildings_google	Una huella de edificio de Google dentro de PDET	2.691.812
results	Un agregado por (municipio, fuente)	334 (169 MS + 165 Google)

2.3 Validadores \$jsonSchema

Cada colección tiene un validador `$jsonSchema` instalado con `validationLevel: "moderate"` y `validationAction: "error"`, de modo que los inserts malformados son rechazados en el límite de la base de datos. Los archivos de esquema bajo `schema/` son el contrato canónico; `scripts/init.js` elimina las palabras clave que el subset `$jsonSchema` de MongoDB no soporta (`format`, `$schema`, `$id`) antes de instalar el validador.

El validador detecta: campos requeridos faltantes, tipos incorrectos, códigos DIVIPOLA que no cumplen `^[0-9]{5}$`, valores de confianza fuera de `[0, 1]`, áreas negativas, geometrías distintas a `Polygon / MultiPolygon`, y cualquier campo no declarado en el esquema (`additionalProperties: false`).

2.4 Índices

Colección	Índice	Propósito
municipalities	{geometry: "2dsphere"}	Cruce espacial desde edificios hacia municipios
municipalities	{divipola: 1} unique	Clave de búsqueda, garantía de unicidad
municipalities	{is_pdet: 1}	Filtro económico solo-PDET
buildings_*	{geometry: "2dsphere"}	Consulta espacial inversa (usada en el ETL de etiquetado)
buildings_*	{divipola: 1}	Match en agregaciones por municipio
buildings_*	{source: 1, divipola: 1}	Compuesto para comparación entre fuentes
buildings_*	{confidence: 1} sparse	Filtrar detecciones de baja confianza (solo Google)
results	{divipola: 1, source: 1} unique	Un documento agregado por celda

2.5 Por qué MongoDB específicamente

- **GeoJSON nativo + índices 2dsphere.** `$geoWithin` / `$geoIntersects` resuelven las consultas de cruce espacial sin bibliotecas externas.
- **Documento por edificio** coincide con la granularidad natural de ambos datasets aguas arriba (MS entrega GeoJSONL, Google entrega CSV-con-WKT).
- **Framework de agregación** maneja el pipeline analítico de extremo a extremo (`$match` → `$group` → `$lookup` → `$project`).
- **Operativamente económico.** Un solo contenedor de Mongo soporta el subset PDET completo; no se requiere clustering.

Alternativas consideradas y rechazadas: **PostGIS** (descartado — SQL), **Elasticsearch** (excesivo, ergonomía de agregación más débil), **Redis Geo** (solo puntos, sin consultas de polígonos), **Couchbase** (historia geo más débil).

3. Metodología — Proceso de Extremo a Extremo

El pipeline tiene la misma forma de cinco etapas que se siguió cada semana:

SCOPE	→ Polígonos de municipios PDET en `municipalities`
INGEST	→ Huellas de edificios en `buildings_ms` / `buildings_google`
TAG	→ Cada edificio recibe su DIVIPOLA contenedor en el insert
AGGREGATE	→ Pipeline de MongoDB agrupa por (divipola, fuente) → `results`
VISUALIZE	→ Exportes CSV, gráficas PNG, mapas Folium interactivos

El resto de esta sección documenta cada fase con el script que la ejecutó, qué consume y qué produce.

3.1 Fase 1 — Fundamentos (Semana 1)

Objetivo. Materializar la forma de la base de datos: colecciones, validadores, índices.

Paso	Comando	Entradas	Salidas
Levantar Mongo + Mongo Express	<code>docker compose up -d</code>	<code>docker-compose.yml</code>	<code>upme-mongo:27017</code> , <code>upme-mongo-express:8081</code>
Crear colecciones + validadores + índices	<code>mongosh ...</code> <code>/scripts/init.js</code>	<code>schema/*.json</code>	Cuatro colecciones vacías en <code>upme</code>
Prueba de humo	<code>mongosh ...</code> <code>/scripts/smoke_load.js</code>	(sintético)	Prueba el esquema + etiquetado + pipeline de agregación sobre datos falsos

La prueba de humo de la Semana 1 inserta un polígono sintético de Tumaco más ~1.400 edificios falsos, los etiqueta vía `$geoWithin` , ejecuta el pipeline de agregación y escribe totales por fuente en `results` — ejercitando cada pieza del diseño antes de que llegue data real.

3.2 Fase 2 — Polígonos de municipios PDET (Semana 2)

Objetivo. Cargar los 170 polígonos PDET en `municipalities` .

Paso	Comando	Entradas	Salidas
Adquisición	(manual)	DANE MGN 2025 ZIP, ART <code>MunicipiosPDET.xlsx</code>	<code>data/raw/municipios_colombia.geojson</code> , <code>data/raw/pdet_municipios.csv</code>
Validar + filtrar + reproyectar	<code>python</code> <code>scripts/validate_pdet.py</code>	los dos archivos anteriores	<code>data/processed/pdet_municipios.geojson</code> (169 features, 65 MB), <code>docs/week2-validation.md</code>
Cargar en Mongo	<code>python</code> <code>scripts/load_municipalities.py</code>	GeoJSON limpio	<code>upme.municipalities</code> poblado, consultas de validación impresas

El script de validación ejecuta once verificaciones automatizadas antes de que algo llegue a Mongo: CRS = EPSG:4326, columnas requeridas presentes, 170/170 códigos PDET encontrados, sin duplicados, tipos de geometría restringidos a (Multi)Polygon, validez geométrica (`shapely.is_valid` + `make_valid`), sin geometrías vacías, bounding box dentro de Colombia, área total en rango razonable (389.182 km² ≈ 34 % de Colombia, coincide con cifras publicadas por la ART), 16 subregiones PDET presentes, y se escribe la salida limpia.

La fuente de adquisición original para los polígonos fue DANE MGN 2025; para el snapshot actual de `Proyecto-DBA` se usó GADM 4.1 en la ruta alterna de recarga. GADM 4.1 carece de **San José de Uré (DIVIPOLA 23580)**, creado en 2012 por separación de Montelíbano — esa es la razón por la cual la colección final `municipalities` contiene 169

documentos en lugar de 170. La omisión afecta menos del 0,05 % del inventario de edificios PDET y está documentada en §6 (Limitaciones).

3.3 Fase 3 — Huellas de edificios (Semana 3)

Objetivo. Cargar edificios de Microsoft y Google, filtrados a territorio PDET y etiquetados con su DIVIPOLA contenedor.

Paso	Comando	Entradas	Salidas
Descubrir teselas de Colombia	(embebido en el script de descarga)	Microsoft <code>dataset-links.csv</code> , Google <code>score_thresholds_s2_level_4.csv</code>	232 quadkeys MS + 8 celdas S2 Google que cubren el bbox PDET
Descargar	<code>python scripts/download_buildings.py</code>	URLs de teselas	<code>data/raw/ms_buildings/*.csv.gz</code> (647 MB), <code>data/raw/google_buildings/*.csv.gz</code> (2,9 GB)
Cargar con cruce espacial en el insert	<code>python scripts/load_buildings.py</code>	teselas descargadas + <code>upme.municipalities</code>	<code>upme.buildings_ms</code> (1.763.356), <code>upme.buildings_google</code> (2.691.812)
Auditoría inicial de datos	<code>python scripts/eda_buildings.py</code>	ambas colecciones de edificios	<code>docs/week3-eda.md</code>

La pieza ingeniosa. El cruce espacial se realiza en el INSERT (no como pasada ETL posterior). Los 169 polígonos PDET se cargan de Mongo una sola vez a un índice espacial **STRtree** (R-tree) de Shapely. Para cada edificio, se consulta el `representative_point()` del polígono — un punto interior garantizado, a diferencia de un centroide ingenuo que podría caer fuera de polígonos cóncavos — contra el STRtree. Los edificios cuyo punto interior cae fuera de cualquier polígono PDET se descartan antes de llegar a Mongo.

Throughput: ~6.500 inserts/s (Microsoft), ~4.900 inserts/s (Google). Las tasas de descarte fuera-de-PDET fueron 79 % (MS) y 91 % (Google), como se esperaba — los quadkeys y celdas S2 cubren regiones enteras de bounding box, la mayoría de las cuales se extiende mucho más allá de los 170 polígonos PDET.

3.4 Fase 4 — Análisis de agregación (Semana 4)

Objetivo. Producir totales por municipio y fuente, más análisis de sensibilidad y visualizaciones.

Paso	Comando	Entradas	Salidas
Agregación + sensibilidad + mapas + gráficas	<code>python scripts/analyze.py</code>	ambas colecciones de edificios + <code>municipalities</code>	<code>upme.results</code> (334 docs), <code>data/processed/results_summary.csv</code> , <code>data/processed/sensitivity_google.csv</code> , <code>docs/chart_*.png</code> (4), <code>docs/map_*.html</code> (4), <code>docs/week4-report.md</code>

El pipeline de agregación corre de manera independiente sobre cada colección `buildings_*` :

```
$match → {divipola: {$ne: null}} # solo PDET
$group → por divipola: count, sum(area), avg(area), $percentile(area, 0.5)
$lookup → municipalities (para name, department)
$unwind → aplanar el arreglo de lookup
$project → dar forma según results.schema.json
```

Cada documento resultado es escrito por `upsert` en `upme.results` con la clave compuesta única (`divipola, source`) . La mediana se calcula usando el acumulador `$percentile` de MongoDB 7 con `method: "approximate"` (algoritmo t-digest) — memoria acotada, precisión dentro del ~1 % de la mediana verdadera. Esta es la única operación del pipeline que requiere Mongo 7.

El pipeline de Google se re-ejecuta a seis umbrales de confianza (0,60, 0,65, 0,70, 0,75, 0,80, 0,90) para análisis de sensibilidad; Microsoft no incluye un puntaje de confianza por edificio y se trata como un único punto.

4. Resultados y Visualizaciones de Datos

4.1 Totales nacionales

Métrica	Microsoft	Google	Ratio (G / MS)
Edificios	1.763.356	2.691.812	1,53×
Área total de cubierta (km²)	221,18	222,90	1,01×
Área media por edificio (m²)	114,55	80,61	0,70×
Municipios con datos	169	165	—

El área total de cubierta converge dentro del 1 % entre las dos fuentes de datos independientes. Esta es la evidencia más fuerte disponible de que nuestro filtro espacial es correcto: dos pipelines independientes basados en imágenes satelitales, con arquitecturas y conjuntos de entrenamiento completamente distintos, ambos llegan a ~222 km² de cubiertas en territorio PDET.


Google reporta **53 % más edificios** mientras observa un área total similar, porque Google detecta huellas sustancialmente más pequeñas en todos los percentiles (mediana 58 m² vs. 77 m² para Microsoft). Los dos métodos ven el mismo inventario de edificios — lo rebanan de distinta forma. Google es más sensible a estructuras pequeñas o informales; Microsoft las agrupa o filtra como ruido.

4.2 Municipios líderes por área de cubierta

Los principales municipios PDET por área de cubierta son grandes capitales departamentales que están dentro de territorio PDET:

DIVIPOLA	Nombre	Departamento	Área MS (km²)	Área Google (km²)
47001	Santa Marta	Magdalena	14,18	16,00
20001	Valledupar	Cesar	13,53	15,41
76109	Buenaventura	Valle del Cauca	7,27	7,70
18001	Florencia	Caquetá	6,67	7,35
05837	Turbo	Antioquia	4,59	5,96
52835	San Andrés de Tumaco	Nariño	4,51	3,71
19698	Santander de Quilichao	Cauca	4,24	3,85
54810	Tibú	Norte de Santander	3,55	2,65

El área de cubierta combinada de los 5 primeros (~46 km²) corresponde aproximadamente al **20 % del área total de cubierta PDET** — es decir, una quinta parte del potencial solar PDET nacional se concentra en cinco municipios.





4.3 Concordancia y discrepancia entre fuentes

Los dos datasets concuerdan estrechamente en el área **total** de cubierta pero discrepan sustancialmente en los conteos **por municipio**:

- 169 / 170 municipios tienen detecciones de Microsoft
- 165 / 170 municipios tienen detecciones de Google
- 165 municipios están cubiertos por ambas fuentes
- **126 de 165** municipios compartidos (76 %) muestran discrepancia mayor al 20 % en el conteo bruto de edificios

Building Count per Municipality: MS vs Google






El scatter de área es notablemente más ajustado que el scatter de conteo — la concordancia sobre el área agregada de cubierta es mucho más fuerte que sobre el conteo bruto. Este es el hallazgo analítico principal: **ninguna fuente individual es autoritativa al nivel de municipio**, pero las dos juntas convergen en un total defendible.

4.4 Sensibilidad al umbral de confianza de Google

Las detecciones de Google llevan un puntaje de confianza en `[0,60, 1,00]` (0,60 es el piso del release v3). El pipeline se re-ejecutó a seis umbrales:

Confianza mínima	Municipios con datos	Edificios	Área total de cubierta (km ²)
0,60	165	2.691.812	222,90
0,65	165	2.691.812	222,90
0,70	165	2.261.910	207,42
0,75	164	1.751.854	180,57
0,80	164	1.119.363	132,10
0,90	163	77.003	20,76



Subir el umbral de 0,60 → 0,70 elimina 430 K edificios pero conserva el **93 % del área total** — las detecciones de baja confianza que se descartan son predominantemente estructuras pequeñas (el "ruido" de cola larga). Por encima de 0,80 el análisis pierde cobertura significativa. **0,70 es el umbral operativo recomendado** para uso posterior: elimina las detecciones más ruidosas conservando el área analíticamente importante.

4.5 Mapas coropléticos interactivos

Cuatro mapas coropléticos interactivos en Folium cubren el producto cruzado de fuente × métrica:

- [docs/map_microsoft_building_count.html](#)
- [docs/map_microsoft_rooftop_area.html](#)
- [docs/map_google_building_count.html](#)
- [docs/map_google_rooftop_area.html](#)

Cada mapa muestra Colombia con los municipios PDET coloreados por la métrica correspondiente y un tooltip al pasar el cursor que expone DIVIPOLA, nombre, departamento y valor.

5. Recomendaciones para la UPME

Las siguientes recomendaciones son el producto específico y accionable del análisis, dirigidas al equipo de localización solar de la UPME.

Recomendación 1 — Priorizar los 5 municipios urbano-PDET principales

Santa Marta, Valledupar, Buenaventura, Florencia y Turbo lideran a todos los demás municipios PDET por área de cubierta con amplio margen (cada uno > 4 km² en ambas fuentes). Ambas fuentes concuerdan en el orden. **Estos son los candidatos recomendados para el despliegue de la primera granja solar piloto.**

Recomendación 2 — Usar Google con `confidence ≥ 0,70` como inventario principal

El dataset Google Open Buildings v3 es el mayor y más granular de los dos. Aplicado con un piso de confianza de 0,70, conserva el 93 % del área total de cubierta eliminando el 16 % más ruidoso de las detecciones. Microsoft Building Footprints sirve como verificación cruzada.

Recomendación 3 — Verificación en terreno antes de comprometer capital

En cualquier municipio donde Microsoft y Google discrepen más del 20 % en conteo de edificios (126 de 165 municipios compartidos), los dos datasets no pueden producir conjuntamente una estimación confiable. Antes de comprometer capital en un municipio fuera del top 5, la UPME debe verificar en terreno con visita o imágenes de mayor resolución.

Recomendación 4 — Re-ejecutar anualmente

Microsoft y Google publican detecciones actualizadas de edificios con una cadencia aproximadamente anual. El pipeline es reproducible desde un clon limpio en menos de 30 minutos (excluyendo el tiempo de descarga). La UPME debería re-ejecutar el análisis cada año y versionar la colección `results` por `computed_at`.

Recomendación 5 — Considerar ampliar el alcance a todas las capitales departamentales

Los candidatos más fuertes del análisis son todos capitales departamentales que están dentro de territorio PDET. Para una planeación solar más amplia, la UPME puede querer replicar esta metodología sobre las 32 capitales departamentales colombianas como referencia comparable de cubierta urbana.

Resumen cuantitativo

- ~222 km² de área total de cubierta PDET disponible
 - ~46 km² concentrados en los 5 municipios principales (~ 20 % del total)
 - 5 de 5 municipios líderes concuerdan entre las dos fuentes
 - 126 de 165 municipios compartidos requieren verificación en terreno
-

6. Limitaciones y Salvedades

#	Limitación	Impacto	Mitigación
6.1	GADM 4.1 (la fuente de polígonos en este snapshot) carece de San José de Uré (DIVIPOLA 23580), un municipio creado en 2012. El conteo resultante de <code>municipalities</code> es 169, no 170.	< 0,05 % del inventario de edificios PDET.	Re-ejecutar la Semana 2 contra DANE MGN 2025 para recuperar el municipio faltante.
6.2	La mediana del área de cubierta se calcula vía la aproximación t-digest de <code>\$percentile</code> .	Los valores de mediana son precisos dentro del ~1 % de la mediana verdadera.	Aceptable para ranking y agrupación por tiers. Para medianas exactas, <code>\$sort + \$arrayElemAt</code> por grupo podría reemplazar el acumulador con mayor costo de memoria.
6.3	Google Open Buildings v3 tiene un piso duro de confianza en 0,60. El análisis de sensibilidad no puede evaluar detecciones por debajo de ese umbral.	Cola larga desconocida de detecciones pequeñas adicionales.	Futuros releases de Google podrían bajar el piso; el código de barrido acepta umbrales arbitrarios.
6.4	Microsoft calcula el área mediante reproyección a EPSG:9377; Google usa su campo fuente <code>area_in_meters</code> (calculado por el pipeline de Google). Las metodologías no son idénticas.	El área media difiere (114,55 vs 80,61 m ²) pero el área total converge. La diferencia está dominada por la sensibilidad de detección, no por la metodología de cálculo del área.	Documentado; un analista puede recalcular las áreas de Google vía EPSG:9377 si se requiere simetría metodológica exacta.
6.5	Un pequeño número de polígonos (< 0,01 % del corpus insertado) son rechazados por el índice 2dsphere de Mongo por geometría esférica degenerada.	Despreciable.	Visible en los logs de carga; <code>insert_many(ordered=False)</code> permite que el resto continúe.
6.6	El área de cubierta ≠ área solar utilizable. La orientación del techo, la pendiente, la sombra y la condición estructural no se evalúan.	La salida es una cota superior del potencial solar. Los modelos posteriores de la UPME consideran estos factores.	Fuera de alcance; documentado para consumidores posteriores.
6.7	La designación PDET se define en el Decreto 893/2017 y puede modificarse en legislación futura.	El pipeline está anclado en códigos DIVIPOLA, que son estables. Si la lista PDET cambia, solo se necesita actualizar <code>data/raw/pdet_municipios.csv</code> .	Documentado.

7. Reproducibilidad

7.1 Inicio rápido (desde un clon limpio)

```
# Prerrequisitos: Docker, Python 3.13, Git
git clone https://github.com/Jxxxlian/Proyecto-DBA.git
cd Proyecto-DBA

# Levantar Mongo
docker compose up -d

# Crear colecciones + validadores + índices
docker compose exec mongo mongosh -u root -p root \
  --authenticationDatabase admin /scripts/init.js

# Entorno Python
python -m venv .venv && .venv/Scripts/activate
pip install pymongo shapely pyproj requests geopandas pandas folium matplotlib openpyxl

# Fase 2: Polígonos PDET
# (descargar el GeoJSON DANE MGN 2025 según data/raw/SOURCES.md)
python scripts/validate_pdet.py
python scripts/load_municipalities.py

# Fase 3: Huellas de edificios
python scripts/download_buildings.py
python scripts/load_buildings.py
python scripts/eda_buildings.py

# Fase 4: Análisis
python scripts/analyze.py
```

Navegar la base de datos en `http://localhost:8081` (admin / admin).

7.2 Tiempo y almacenamiento

Fase	Tiempo	Huella en disco
Fase 1 (Mongo + init.js)	< 1 min	~0
Fase 2 (validar + cargar 169 polígonos)	< 1 min	65 MB
Fase 3a (descargar teselas)	~30 min (limitado por red)	3,5 GB comprimidos
Fase 3b (cargar 4,4 M edificios)	~15 min	~15 GB en disco en Mongo
Fase 4 (analizar + mapas + gráficas)	~3 min	~10 MB de salidas
Tiempo total	~50 min	~19 GB

7.3 Idempotencia

Todos los loaders son idempotentes. `load_municipalities.py` hace upsert por DIVIPOLA. `load_buildings.py` está rastreado por manifiesto por tesela en `data/processed/buildings_load_manifest.json` — una corrida interrumpida retoma desde donde paró. `analyze.py` hace upsert por `(divipola, source)`.

7.4 Estructura del repositorio

```
Proyecto-DBA/
├─ docker-compose.yml
├─ README.md
├─ data/
│   ├─ raw/          # datasets fuente + notas de adquisición (archivos grandes en .gitignore)
│   └─ processed/    # salidas limpias (geojson, csv)
├─ docs/             # reportes, gráficas, mapas
├─ schema/           # archivos JSON Schema (contrato canónico)
└─ scripts/          # todo el código ETL + análisis
```

8. Alineación con los Objetivos de la UPME

El proyecto entregado cumple cada elemento del mandato declarado por la UPME:

Objetivo de la UPME	Entregado por este proyecto
Usar una solución NoSQL	MongoDB 7 con GeoJSON + 2dsphere
Identificar ubicaciones potenciales para granjas solares en territorio PDET	Ranking de área de cubierta por municipio; recomendación top-5
Comparar datasets abiertos de huellas de edificios	Microsoft Bing + Google Open Buildings v3
Metodología reproducible	Ruta de reproducción de cinco comandos; loaders idempotentes; descargas rastreadas por manifiesto
Soportar modernización y escalabilidad	Validadores de esquema, índices, valores derivados denormalizados; el diseño generaliza a los 1.122 municipios colombianos sin cambios de código
Proveer un reporte técnico con recomendaciones	Este documento

9. Conclusión

Este proyecto demuestra que una metodología basada en datos abiertos y NoSQL puede producir un inventario defendible del potencial solar de cubiertas en los 170 municipios PDET de Colombia. Al comparar dos datasets independientes de huellas de edificios derivadas de satélites y converger en un total único dentro del 1 %, el análisis entrega a la UPME tanto una cifra sobre la cual actuar (~222 km² de área de cubierta PDET, con el 20 % concentrado en cinco municipios) como una rendición de cuentas transparente sobre dónde esa cifra es y no es confiable (126 de 165 municipios discrepan a nivel de conteo).

El entregable no es solo las tablas de resultados y las visualizaciones — es también el pipeline reproducible. Cuando Microsoft o Google publican nuevas detecciones de edificios, la UPME re-ejecuta cuatro scripts y obtiene cifras actualizadas. Cuando el alcance legal PDET cambia, se actualiza un archivo CSV. La metodología sobrevive a los datos.

Para el siguiente paso inmediato de la UPME — localizar una granja solar piloto — el análisis recomienda **Santa Marta, Valledupar, Buenaventura, Florencia o Turbo**, en ese orden.

Apéndice A — Mapeo a los Requisitos del Proyecto

Requisito del documento de referencia	Este reporte
§1 Introducción: flujo geoespacial reproducible	§3 Metodología
§1 Estimar potencial solar de cubiertas	§4 Resultados
§1 Análisis de territorios PDET	§2 Arquitectura; §3.2 Fase 2
§2 Identificar ubicaciones para granjas solares piloto	§5 Recomendaciones
§2 Determinar número de edificios y área agregada por municipio PDET	§4.1, §4.2; Apéndice B
§2 Aplicar soluciones NoSQL	§2 Arquitectura
§2 Evaluar datasets abiertos y comparar resultados	§4.3 Concordancia entre fuentes
§2.1 Al menos dos de tres datasets	Microsoft + Google (§3.3)
§2.2 MGN: extraer y filtrar a territorios PDET	§3.2 Fase 2
§3.1.5 Reporte final — Documentación del proceso	§3 Metodología
§3.1.5 Reporte final — Resultados y visualizaciones	§4 Resultados
§3.1.5 Reporte final — Contenido y Completitud	Este apéndice
§3.1.5 Reporte final — Claridad de Recomendaciones	§5 Recomendaciones
§3.1.5 Reporte final — Alineación con Objetivos de la UPME	§8 Alineación

Apéndice B — Top 20 municipios PDET por área de cubierta (Microsoft)

Ver `data/processed/results_summary.csv` para la tabla completa de 334 filas. Líderes seleccionados:

DIVIPOLA	Nombre	Departamento	Conteo MS	Área MS (km²)	Conteo Google	Área Google (km²)
47001	Santa Marta	Magdalena	67.435	14,18	183.114	16,00
20001	Valledupar	Cesar	64.088	13,53	171.908	15,41
76109	Buenaventura	Valle del Cauca	34.382	7,27	104.324	7,70
18001	Florencia	Caquetá	26.757	6,67	57.994	7,35
05837	Turbo	Antioquia	42.642	4,59	77.890	5,96
52835	San Andrés de Tumaco	Nariño	41.294	4,51	49.702	3,71
19698	Santander de Quilichao	Cauca	30.873	4,24	35.527	3,85
54810	Tibú	Norte de Santander	35.339	3,55	32.767	2,65
18753	San Vicente del Caguán	Caquetá	22.363	3,54	22.232	2,67
81065	Araucita	Arauca	29.059	3,46	36.164	3,02
05045	Apartadó	Antioquia	10.304	3,45	37.193	3,70
19256	El Tambo	Cauca	37.012	3,29	43.200	2,71
95001	San José del Guaviare	Guaviare	21.535	3,11	32.798	3,17
81736	Saravena	Arauca	17.499	3,08	27.625	2,19
86568	Puerto Asís	Putumayo	20.266	2,96	26.218	2,56
23807	Tierralta	Córdoba	29.628	2,93	42.469	3,04
81794	Tame	Arauca	20.687	2,73	35.728	3,18
23466	Montelíbano	Córdoba	21.096	2,70	30.083	2,66
19142	Caloto	Cauca	16.173	2,33	24.041	2,79
19548	Piendamó	Cauca	17.339	2,29	31.395	2,71

Apéndice C — Procedencia de las Fuentes

Fuente	URL	Licencia	Descargado
DANE MGN 2025 (polígonos municipales)	https://geoportal.dane.gov.co/servicios/descarga-y-metadatos/datos-geoestadisticos/?cod=111	Pública, con atribución	2026-05-09
Lista ART PDET	https://centralpdet.renovacionterritorio.gov.co/wp-content/uploads/2022/01/MunicipiosPDET.xlsx	Pública	2026-05-10
Microsoft Global Building Footprints	https://planetarycomputer.microsoft.com/dataset/ms-buildings	ODbL	2026-05-11
Google Open Buildings v3	https://sites.research.google/open-buildings/	CC BY-4.0 / ODbL	2026-05-11

Procedencia completa, tamaños de archivo e instrucciones de reproducción en `data/raw/SOURCES.md`.